

ACP - Facultatif

On conserve les séries A et B du TP précédent.

Nous travaillerons exclusivement avec les séries **centrées-réduites**, car c'est le prétraitement indispensable avant une ACP.

On note :

$$A_i^* = \frac{A_i - \mu_A}{\sigma_A}, \quad B_i^* = \frac{B_i - \mu_B}{\sigma_B}.$$

1. Calcul des séries centrées-réduites

1. À partir des résultats précédents, rappeler les valeurs de :

$$\mu_A, \sigma_A$$

$$\mu_B, \sigma_B$$

2. Calculer explicitement les trois premières valeurs centrées-réduites des deux séries :

Par exemple :

$$A_1^* = \frac{12 - \mu_A}{\sigma_A}, \quad A_2^* = \frac{18 - \mu_A}{\sigma_A}, \quad A_3^* = \frac{25 - \mu_A}{\sigma_A}.$$

Faire de même pour :

$$B_1^*, B_2^*, B_3^*.$$

3. Vérifier par un calcul direct que :

$$\frac{1}{n} \sum_{i=1}^n A_i^* = 0, \quad \frac{1}{n} \sum_{i=1}^n B_i^* = 0,$$

et que les variances valent bien 1.

On pourra calculer une moyenne approchée avec seulement les 5 premières valeurs pour tester.

2. Calcul du coefficient de corrélation

Le coefficient de corrélation entre les séries centrées-réduites se calcule par :

$$r = \frac{1}{n} \sum_{i=1}^n A_i^* B_i^*.$$

1. Calculer les produits $(A_i^* B_i^*)$ pour les cinq premières valeurs.
2. En déduire une approximation du coefficient de corrélation (sur cinq valeurs).
3. Donner ensuite le coefficient exact avec Python ou une calculatrice.

Questions :

- Le coefficient est-il positif, négatif, proche de 1 ou 0 ?
 - Les variations des deux séries sont-elles liées ?
 - Peut-on dire qu'une partie de la variabilité de B est expliquée par A ?
-

3. Construction du nuage de points dans

$$(A^*, B^*)$$

Représenter chaque observation sous forme de point :

$$P_i = (A_i^*, B_i^*).$$

Consignes :

1. Tracer le nuage de points en utilisant les valeurs normalisées.
2. Identifier visuellement :
 - s'il existe une direction dominante (un alignement approximatif),
 - si les points sont plutôt étalés ou regroupés.

Guidage :

Calculer :

$$P_1 = (A_1^*, B_1^*), \quad P_2 = (A_2^*, B_2^*), \quad P_3 = (A_3^*, B_3^*).$$

Questions :

- Le nuage semble-t-il pencher dans une direction particulière ?
 - Cette direction correspond-elle à une relation linéaire entre A et B ?
-

4. Identification d'un axe principal (idée essentielle de l'ACP)

À partir du nuage de points centrés-réduits :

1. Dessiner une droite qui semble suivre la tendance générale du nuage.
2. Projeter quelques points sur cette droite (en traçant les perpendiculaires).

Guidage de calcul :

Pour un axe donné par une direction vectorielle normalisée $u = (u_1, u_2)$, la projection de (P_i) est :

$$c_i = A_i^* u_1 + B_i^* u_2.$$

1. Choisir une direction simple, par exemple

$$u = \left(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}} \right)$$

si A et B sont corrélées positivement.

2. Calculer les projections c_1, c_2, c_3 .
3. Commenter ce que représentent ces valeurs projetées.

Questions :

- La projection condense-t-elle l'information de manière cohérente ?
 - Les projections ordonnent-elles les observations de façon similaire aux séries initiales ?
 - Pourquoi ce procédé constitue-t-il une réduction de dimension ?
-

5. Transition finale vers l'ACP formelle

Rédiger une conclusion guidée :

1. Pourquoi devait-on d'abord centrer-réduire les données ?
2. Pourquoi le coefficient de corrélation est-il crucial pour comprendre la structure du nuage ?
3. Pourquoi l'axe que l'on a dessiné s'apparente-t-il à la première composante principale ?
4. Comment l'ACP formalise-t-elle :
 - la recherche de l'axe maximisant la variance,
 - le calcul automatique des projections,
 - la réduction de dimension à un seul axe ?